

LLaMA-2-70B 单卡 H200 仿真与推理性能全景分析报告

基于显存刚性约束、MHA 架构开销、独占式调度与抢占重算惩罚的严谨推导

硬件配置: 1× NVIDIA H200 SXM (141 GiB HBM3e) 模型架构: LLaMA-2-70B (MHA, TP=PP=DP=1)

负载规格: 100 Synthetic Requests (P512 / D512)

1. 硬件集群与模型配置画像 (Configuration)

1.1 硬件算力与显存拓扑

参数项	数值与特性
GPU 型号	NVIDIA H200 SXM (1 卡)
显存容量	141 GiB HBM3e (约 151.4 GB)
显存带宽	4.8 TB/s (4800 GB/s)
算力指标	1979 TFLOPS (BF16 Tensor Core)
并行策略	TP=1, PP=1, DP=1 (无分布式通信)

1.2 模型架构基准 (LLaMA-2-70B)

架构项	数值与说明
总参数量	~68.97 B (全量 BF16/FP16)
网络层数 (L)	80 层
隐藏层 (D_{model})	8192
注意力机制	标准 MHA (64 Heads), 非 GQA
Head 维度	$d_k = d_v = 128$ (8192 / 64)

1.3 负载画像与校准运行时约束

- 负载总请求数: 100 个合成请求 (Synthetic Requests)。
- 长度规格: Prefill 阶段 512 ± 32 tokens, Decode 阶段 512 ± 32 tokens; 单请求峰值上下文满长严格按 1024 tokens 核算。
- 显存分配校准: 静态模型权重占用 120.76 GiB, 留给动态 KV Cache 的池化预算为 20 GiB (Paged Block Size = 16)。
- 访存惩罚因子: $\text{DECODE_SCALE} = 1 / 0.55 \approx 1.818$, 精确反映系统在复杂访存与带宽利用率下的实测折损 (实际有效显存带宽约为 55%)。

2. 显存瓶颈与刚性并发推导 (Memory & Concurrency)

由于 LLaMA-2-70B 采用原生 Multi-Head Attention (MHA) 而未引入 Grouped-Query Attention (GQA), 其每个 Token 的 Key/Value 缓存开销极大:

$$\text{KV Bytes per Token} = 2 \times L \times D_{\text{model}} \times 2 \text{ Bytes} = 2 \times 80 \times 8192 \times 2 = 2,621,440 \text{ Bytes} = 2.50 \text{ MiB/token}$$

当单个请求流转至生命周期终点 (满长 1024 tokens) 时, 该请求独占的 KV Cache 峰值显存为:

$$\text{Peak KV}_{\text{req}} = 1024 \text{ tokens} \times 2.50 \text{ MiB/token} = 2560 \text{ MiB} = 2.50 \text{ GiB}$$

并发上限刚性收敛：

在 141 GiB 总显存中，扣除静态权重 120.76 GiB 后仅剩余 20 GiB 动态空间。调度器为杜绝爆显存（OOM），准入的最大并发批次必须满足：

$$B_{\max} = \lfloor 20 \text{ GiB} / 2.50 \text{ GiB} \rfloor = 8$$

这决定了即便 H200 拥有 1979 TFLOPS 的强劲算力，也无法通过打大 Batch Size 提升吞吐，系统完全处于极小 Batch 的访存墙（Memory-Bound）受限状态。

3. 步长延迟与生成吞吐建模 (Decode Dynamics)

3.1 Decode 单步延迟模型 (t_{step})

在极小并发 ($B \approx 8$) 下，计算量远不足以掩盖访存延迟。单步执行耗时由权重搬运基底与 Attention 访存计算两部分叠加：

$$t_{\text{step}} \approx 32.6 \text{ ms} \times 1.818 + B \cdot t_{\text{attn}} \approx 65 \sim 70 \text{ ms} \quad (\text{对齐实测 p50} = 69 \text{ ms})$$

- **权重搬运基底**： $32.6 \text{ ms} \times 1.818 \approx 59.3 \text{ ms}$ ，对应 120.76 GiB 权重在 55% 有效带宽 ($4.8 \text{ TB/s} \times 0.55$) 下的传输耗时。
- **Attention 与算子开销**： $B \cdot t_{\text{attn}} \approx 6 \sim 10 \text{ ms}$ ，包含 PagedAttention 寻址、KV 搬运及 Kernel Launch 开销。

3.2 单流速度与聚合吞吐

$\approx 14.5 \text{ tok/s}$

单流体感生成速率 ($1 / 0.069\text{s}$, ITL $\approx 69 \text{ ms}$)

120 ~ 150 tok/s

Decode 稳态聚合吞吐 (有效并发 6~8 动态浮动)

4. 调度流转、抢占与重算惩罚 (Scheduling & Recomputation)

本配置下的系统执行特征与传统流水存在本质区别，调度细节如下：

1. **首波 Packed Prefill**：系统冷启动时显存全空，调度器一次性打包进约 **16 条请求**，纯计算 Prefill 耗时仅为 **~ 0.87 秒**。
2. **整步独占切换（非 Chunked 气泡）**：Prefill / Recompute 与 Decode 不采用交错切片气泡，而是**整步独占切换**。当需要执行 Prefill 或恢复被抢占请求时，Decode 完全让出算力，形成显式的阶段停顿。
3. **73 次抢占与 $\sim 10\text{s}$ 重算惩罚**：当多个并发请求步入后半程、累计长度逼近 1024 时，20 GiB KV 预算耗尽。系统被迫触发 **73 次抢占（Eviction）**，将部分请求踢出显存并在后续换入时执行 **Recomputation**，累计产生 **~ 10 秒的纯重算开销**。

5. 端到端性能汇总与核心指标 (End-to-End Metrics)

综合 Prefill、稳态 Decode、调度流转及重算，整个 Workload 的总执行时间与吞吐严格闭环：

$$\text{Makespan} \approx T_{\text{decode}} + T_{\text{prefill_init}} + T_{\text{recompute}} \approx (100 \times 512 / 150) + 0.87 \text{ s} + 10 \text{ s} \approx 351 \text{ 秒}$$

评估维度 / 指标	仿真与实测值	底层机理与瓶颈归因
单步步长 (t_{step})	65 ~ 70 ms (p50: 69 ms)	120.76 GiB 权重访存基底 + $\text{DECODE_SCALE}=1/0.55 + B \cdot t_{\text{attn}}$
单用户体感速率	$\approx 14.5 \text{ tokens/s}$	等于 $1 / \text{ITL}$ ，每步耗时 69 ms 输出 1 token
Decode 聚合吞吐	$\sim 120 - 150 \text{ tokens/s}$	并发度非恒定 8，在 6~8 间波动的聚合输出能力
初始 Prefill 耗时	$\sim 0.87 \text{ 秒}$	第一波 Packed Prefill ~ 16 条请求的瞬时计算开销
调度抢占与重算	73 次抢占 / $\sim 10 \text{ 秒重算}$	20 GiB KV 极端紧平衡触发换出，整步切换重算带来延迟放大
总完成时间 (Makespan)	$\sim 351 \text{ 秒 (约 5.85 分钟)}$	完整消化 100 个请求（累计 10.24 万 Token）的端到端耗时
系统端到端总吞吐	$\sim 292 \text{ tokens/s}$	$(51.2\text{k Prefill} + 51.2\text{k Decode}) / 351\text{s}$ 综合吞吐
尾部首字延迟 (TTFT)	$\sim 317 \text{ 秒}$	排在队尾的批次必须等待前序批次及重算全部完成方可入场

6. 瓶颈总结与架构启示

- **MHA 导致显存利用畸形**：LLaMA-2-70B 未采用 GQA 是该场景算力无法释放的核心根因。单 Token 2.50 MiB 的开销锁死了并发扩展空间。
- **整步切换加剧尾部延迟**：非 Chunked 的抢占重算使得尾部请求的 TTFT 膨胀至 317 秒以上，生产环境建议开启 Chunked Prefill 并配合 FP8 量化将权重压缩至 70 GB，从而彻底释放吞吐潜力。